食物组成基础模型的迁移、少样本与稳健性证据

版本： 2026-10-26

主模型： V5+CCE

范围： UMAP 表征、台湾 TFDA 外部零样本、台湾少样本适配、少观测补全、全验证集敏感性分析

目录

摘要

1. 共同设定
2. UMAP 与表征结构
3. 台湾 TFDA 零样本外部验证
4. 台湾 TFDA 少样本适配实验
5. 少量可见 observation 的补全实验
6. 全验证集敏感性分析
7. 综合判断
8. 局限与下一步
9. 复现与附件

摘要

本报告把五组实验放在同一证据框架内，回答三个问题：模型能否迁移到未参与训练的数据库；预训练能否减少新数据所需的标注量；模型在输入稀疏或输入被扰动时如何变化。

结论如下：

1. **台湾 TFDA 零样本是目前最直接的外部迁移证据。** 冻结的 V5+CCE 没有使用任何台湾记录训练、调参或重估归一化尺度。在 2,212 个食品、128,470 个食品-轴任务、80 个轴的严格外部面板上，其 macro scaled-log MAE 为 **0.2296**，分别比 XGBoost、RF 和 KNN 低 **24.6%、26.2% 和 35.1%**。对食品记录进行 2,000 次配对 bootstrap 后，三个差值区间均完全低于零。
2. **新完成的台湾少样本实验显示了明显的预训练初始化优势。** 在名称未精确匹配预训练数据的台湾食品中，使用 8、32、128 个适配食品时，预训练模型的 scaled-log MAE 分别比相同架构从随机初始化训练低 **48.9%、45.7% 和 42.0%**。128 个适配食品还将同一固定测试集上的零样本误差从 0.2258 降到 0.2107。
3. **预训练并不意味着任意少量微调都会改善零样本模型。** 8-shot 微调平均为 0.2337，反而比零样本 0.2258 略差；32-shot 只小幅改善；128-shot 才出现较清楚的收益。低样本下的轴覆盖和抽样方差是实际限制。
4. **少观测补全支持模型在中等稀疏条件下利用跨轴关系。** 在固定 12 个常见目标上，V5+CCE 在 10、20、40 个可见成分时优于 RF 和 KNN；只有 5 个可见成分时 KNN 最好。该实验来自原验证集，属于域内探索性证据。
5. **UMAP 显示表征中存在类别、来源和观测完整度结构，但不能单独证明基础模型优势。** V5+CCE 比原 V5 的类别局部纯度略好，然而原始“数值+缺失标记”基线整体更强；缺失模式本身还能较好识别数据来源，因此二维聚类包含明显的数据覆盖结构。
6. **全验证集敏感性结果总体平滑，但稳健性结论依赖指标。** 对单个正值输入作 ±10% 扰动时，CCE 的平均误差增量很小；输入删除时，CCE 的误差增量显著小于 RF。RF 的干净误差略低，所以小扰动后 RF 的绝对误差仍可能更小。预测变化幅度、误差增量和扰动后绝对误差必须分别报告。

综合来看，**“外部零样本 + 外部少样本预训练/随机初始化消融”构成当前最强的基础模型证据。**UMAP、少观测和敏感性实验用于解释模型学到了什么、在什么条件下受益以及何时失效。

1. 共同设定

1.1 模型

V5+CCE 是单模型、两次前向的数值 Transformer：

- 3 层，hidden dimension 192，6 个 attention heads；
- ReGLU feed-forward block，宽度 256；
- 每层、每个 head 的有序 axis-pair attention bias；
- 第一遍由可见 axis/value token 和目标 axis/[MASK] token 产生目标预测与上下文化的 [FOOD] 表示；
- 第二遍用 detach(h_food) 替换初始 [FOOD]，复用同一个 Transformer，第二遍输出为正式预测；
- CCE 阶段用两次 dropout stochastic view 对第一遍 [FOOD] 表示施加 contrastive cell embedding loss；
- 模型输入不含 food name、source、food family label 或 profile ID。

本报告把完整 checkpoint 称为 **V5+CCE**。现有 continuation
对照说明继续训练本身也能解释一部分变化，因此报告不把所有 V5+CCE 与 V5 的差异都归因于 CCE loss。

1.2 指标

每个轴使用原训练集严格正值的中位数 s_a，将含量变换为

$$z_{i,a}=\log\left(1+\frac{y_{i,a}}{s_a}\right).$$

对每个轴先在食品记录上计算误差，再对所有纳入评价的轴等权平均：

$$\mathrm{SLMAE} =\frac{1}{|\mathcal A|}\sum_{a\in\mathcal A} \frac{1}{N_a}\sum_i |\hat z_{i,a}-z_{i,a}|.$$

报告同时使用 macro scaled-log RMSE 和 macro raw MAE。scaled-log MAE 是主要指标；RMSE 更强调少数较大的对数尺度错误；raw MAE 保留原含量单位并更容易受高浓度轴影响。所有指标均越低越好。

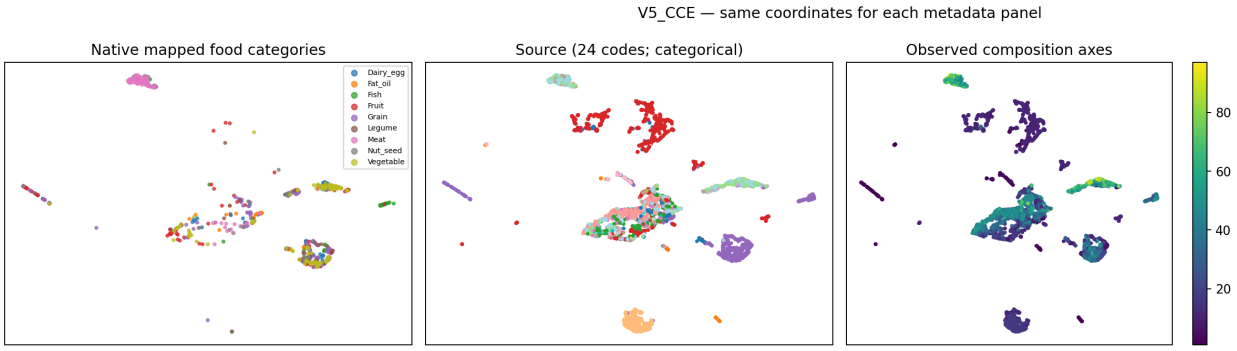
1.3 证据层级

实验	数据角色	是否训练	能回答的问题	证据强度
台湾零样本	独立外部数据库	否	冻结模型能否跨数据库迁移	强
台湾少样本	独立外部数据库；固定测试集	是	预训练是否提高样本效率	强，但只有 3 个 seed
少观测补全	原验证集探索面板	否	可见成分变少时谁更好	中等
UMAP	原训练/验证表征	否	表征包含哪些可分结构	描述性
敏感性分析	原验证集全量诊断	否	输入扰动如何传播到预测与误差	描述性稳健性证据

2. UMAP 与表征结构

2.1 方法

对 75,875 条训练及验证食品记录提取第一遍 Transformer 的 [FOOD] 状态。输入包含全部已观测组成，目标查询集合为空；不输入食品名称或来源。UMAP 只将高维表示投影到二维，不参与训练，也不用于选择 checkpoint。



V5+CCE UMAP

同一二维坐标分别按食品类别、数据来源和已观测轴数量着色。图中可见若干清楚的来源簇和完整度梯度；食品类别在部分区域聚集，但并未形成普遍分离的类别岛。

2.2 定量结果

表征	k=10 purity	k=10 macro purity	线性分类 macro-F1	balanced accuracy	cosine silhouette
原始 nutrients + mask	**0.797**	**0.756**	**0.861**	**0.860**	0.089
PCA-50	0.768	0.725	0.723	0.740	**0.111**
V5	0.719	0.667	0.757	0.776	-0.052

表征	k=10 purity	k=10 macro purity	线性分类 macro-F1	balanced accuracy	cosine silhouette
V5+CCE	0.733	0.689	0.774	0.784	0.066
V5 continuation	0.734	0.682	0.773	0.790	approximately 0.000

V5+CCE 相对 V5 的 k=10 purity 提高约 1.4 个百分点，macro purity 提高约 2.2 个百分点，说明 CCE checkpoint 的局部类别结构有所增强。但 continuation 与 V5+CCE 接近，且直接使用数值与缺失标记的基线整体最好，因此不能声称 FOOD embedding 提取出了超越原始组成的类别表征。

缺失模式本身得到约 0.597 的类别 macro-F1，并能以约 0.967 balanced accuracy 识别来源。这说明 UMAP 簇的一部分来自“哪些轴被某数据库测量”，而非纯粹的食品生物学相似性。

UMAP 随机种子之间的 10 邻域重合约为 0.721。随机隐藏 10%、30%、50% 已观测输入后，V5+CCE 与完整输入表示的平均 cosine similarity 约为 0.980、0.932、0.853，10 邻域重合约为 0.693、0.420、0.244。二维图的局部大结构可重复，但具体位置和细邻域不能作确定性解释。

结论： UMAP 适合作为表征审计和假设生成工具；它显示模型编码了类别、来源和完整度信息，却不是迁移能力的主要证据。

3. 台湾 TFDA 零样本外部验证

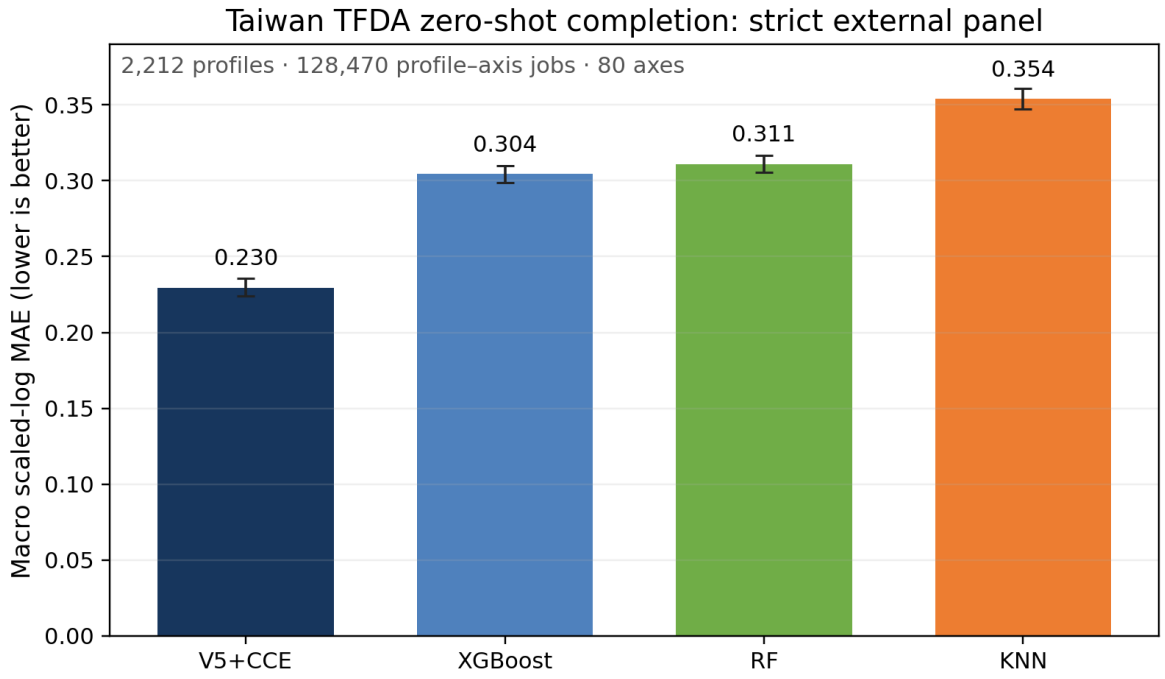
3.1 协议

台湾食品营养数据库在本实验中只用于评价：

- 台湾训练记录数为 0；
- 未用台湾数据调参、选 checkpoint 或重估 `s_a`；
- 目标轴要求映射兼容、有样本量，并在台湾至少有 20 个食品；
- 最终覆盖 80 个轴、8 个目标家族；
- 每个任务隐藏目标所属整个家族；
- V5+CCE 使用冻结 checkpoint；RF、XGBoost、KNN 只在原训练集按既定参数重拟合；
- 指标先在每个轴内平均，再对 80 个轴等权平均；不按来源或同名食品聚合。

严格面板含 2,212 个食品与 128,470 个食品-轴任务。名称新颖面板保留 1,789 个英文名称无法与预训练语料作标准化精确匹配的食品，共 107,482 个任务。这里的“名称未匹配”比来源 ID 未出现更有意义，但仍不能保证语义上完全未见相似食品。

3.2 结果



Taiwan zero-shot

方法	Scaled-log MAE	Scaled-log RMSE	Raw MAE
V5+CCE	**0.2296**	**0.4260**	**0.3658**
XGBoost	0.3044	0.4570	0.3717
RF	0.3111	0.4518	0.3882
KNN	0.3539	0.5395	0.5419

以 scaled-log MAE 计算，V5+CCE 相对 XGBoost、RF、KNN 的改善分别为 24.6%、26.2%、35.1%。食品记录级配对 bootstrap 的差值为：

对照	V5+CCE - 对照	95% paired bootstrap interval	V5+CCE 更好概率
XGBoost	-0.0748	[-0.0773, -0.0723]	1.000
RF	-0.0815	[-0.0841, -0.0789]	1.000
KNN	-0.1243	[-0.1281, -0.1207]	1.000

名称新颖面板得到相同排序：V5+CCE、XGBoost、RF、KNN 的 scaled-log MAE 分别为 0.2311、0.3071、0.3144、0.3587。

Raw MAE 需要更谨慎。V5+CCE 相对 XGBoost 的点估计低 0.0061，但配对区间为 [-0.0126, 0.0008]，跨过零；因此外部优势最清楚地体现在 scaled-log MAE 和 scaled-log RMSE，而不是所有原单位误差上都已得到确定结论。

4. 台湾 TFDA 少样本适配实验

4.1 新实验设计

本轮只使用 1,789 个名称未精确匹配预训练语料的台湾食品。按固定随机种子将其中 400 个食品设为测试集，其余 1,389 个组成适配池。测试集包含 23,109 个食品-轴任务并覆盖全部 80 个轴。

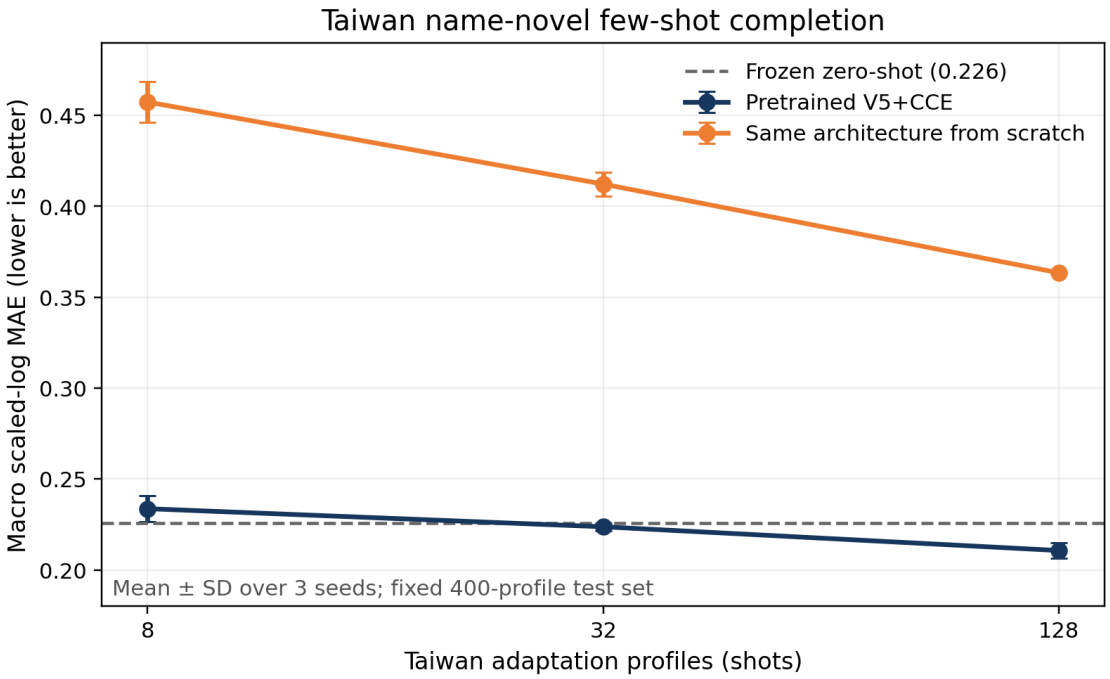
实验比较两种初始化：

1. **Pretrained：** 从 V5+CCE checkpoint 开始；
2. **Scratch：** 相同架构、相同目标、相同 optimizer 和相同训练数据，但参数随机初始化。

对每个 seed 使用嵌套的 8、32、128 个适配食品，即 `8 subset 32 subset 128`。三个 seed 为 20261026、20261027、20261028。每次训练 20 epochs，AdamW，learning rate `1e-4`，batch size 128；固定报告最后一轮，不用测试集选 checkpoint，也不根据中间结果调整设置。

“shot”是食品 profile 数，不是单个轴标签数。由于台湾记录稀疏，8 个食品在三个 seed 中分别覆盖 80、73、74 个可训练目标轴；32 和 128 shot 均覆盖全部 80 个轴。

4.2 结果



Taiwan few-shot

初始化	适配食品数	Scaled-log MAE	Scaled-log RMSE	Raw MAE
Pretrained	8	0.2337 ± 0.0072	0.4340 ± 0.0059	0.3947 ± 0.0113
Scratch	8	0.4574 ± 0.0112	0.6955 ± 0.0266	1.0118 ± 0.0366
Pretrained	32	0.2238 ± 0.0022	0.4214 ± 0.0039	0.3885 ± 0.0021
Scratch	32	0.4122 ± 0.0067	0.6719 ± 0.0099	1.0269 ± 0.0427
Pretrained	128	**0.2107 ± 0.0044**	**0.4083 ± 0.0100**	**0.3747 ± 0.0185**
Scratch	128	0.3634 ± 0.0003	0.6274 ± 0.0087	0.8512 ± 0.0418

固定 400 食品测试集上的冻结零样本 V5+CCE 为 0.2258 / 0.4188 / 0.3870。由此可见：

- 预训练相对随机初始化在 8、32、128 shot 的 scaled-log MAE 分别降低 48.9%、45.7%、42.0%；三个 seed 的每一组配对差值都偏向预训练。
- 8-shot 的预训练微调比零样本差 3.5%，说明极少样本微调会因覆盖不足和抽样偏差破坏原有能力。
- 32-shot 的 scaled-log MAE 比零样本低约 0.9%，但 RMSE 和 raw MAE 没有同步改善，证据较弱。
- 128-shot 的 scaled-log MAE 比零样本低 6.7%，同时 RMSE 和 raw MAE 也改善，是当前最可靠的适配收益点。

这项实验把预训练优势和架构优势分开了一步：两个分支具有相同架构和训练协议，主要差别是初始化。然而它仍只有三个 seed，而且同一 learning rate 与 20-epoch 预算未分别为 scratch 和 pretrained 调优，因此应解释为固定协议下的样本效率证据。

5. 少量可见 observation 的补全实验

5.1 协议

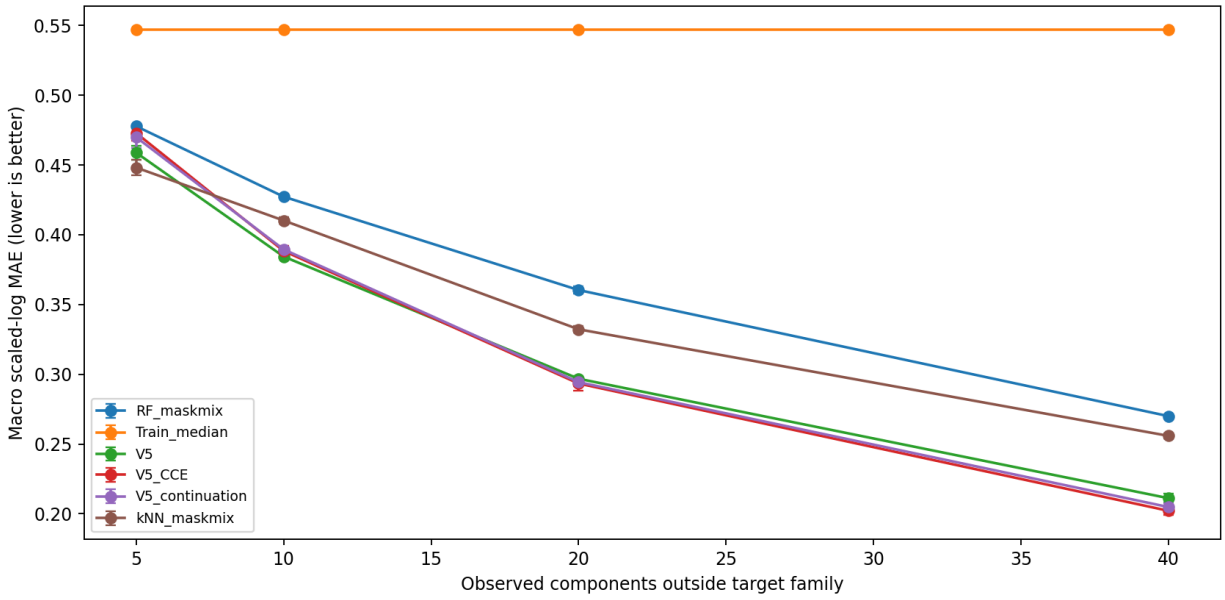
该实验来自原验证集，固定 12 个常见目标、2,400 个食品-目标任务和 1,578 个不同食品。每个任务始终隐藏目标所属整个家族，只把家族外的 5、10、20、40 或全部可见成分提供给模型。5-40 个成分的条件各重复三次随机抽样。

对照包括：

- V5、V5+CCE、V5 continuation；
- RF mask-mix：100 棵树、最大深度 18、叶节点至少 3 条记录，训练时每个 profile 随机一个可见预算；
- KNN mask-mix：16 邻居、cosine distance，使用与 RF 相同的 masked training examples；
- 每目标训练中位数。

这里的 RF/KNN 是专门为稀疏输入重训的 mask-mix 版本，不能与台湾零样本中的正式 187 轴 baseline 数值直接混用。

5.2 结果



Sparse observation completion

可见成分数	RF	KNN	V5+CCE
5	0.478	**0.448**	0.473
10	0.427	0.410	**0.388**
20	0.360	0.332	**0.293**
40	0.270	0.256	**0.202**
全部	0.215	0.191	**0.165**

固定 routine panel 实际平均只有 6.81 个可见成分时，V5+CCE 为 0.3172，V5 为 0.3212，continuation 为 0.3182，KNN 为 0.3908，RF 为 0.4169。

解释： 只有 5 个观测时，局部邻居法更稳；从 10 个观测开始，Transformer 更能利用多个轴之间的联合关系，并且差距随可见信息增加而扩大。CCE 与 continuation 很接近，所以该结果支持“预训练 Transformer 系统”的优势，不能把优势主要归因于 CCE。

6. 全验证集敏感性分析

6.1 设计

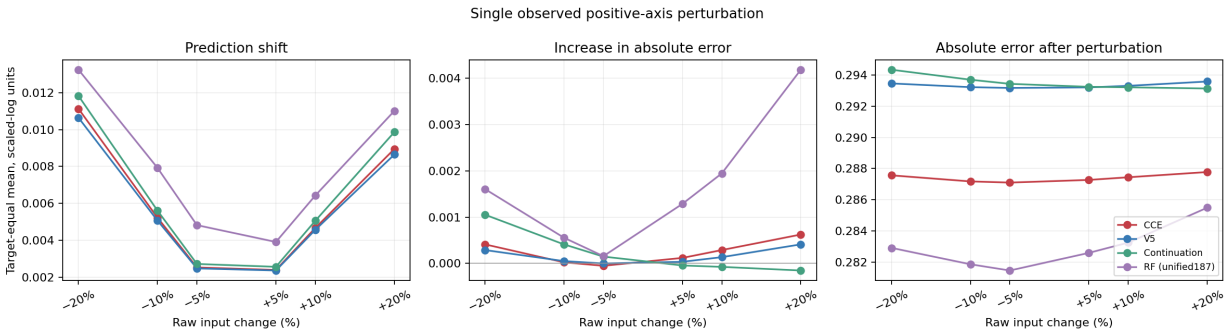
采用完整 11,175 条验证记录、252 个输入轴、187 个目标，未扰动条件覆盖 323,809 个真实食品-目标任务。比较 CCE、V5、等时 continuation 和正式 RF unified187。所有模型隐藏整个目标家族，不输入食品名或来源。

敏感性分析把三个量分开：

- **Prediction shift：** 扰动前后预测的 scaled-log 绝对变化，表示模型是否依赖该输入；
- **Error delta：** 扰动后绝对误差减去扰动前绝对误差，表示扰动是否放大错误；
- **Perturbed error：** 扰动后的绝对误差，包含模型原始准确率和额外退化两部分。

输入操作包括单轴 ±5%、±10%、±20%，单轴移除，零值探针，以及 ×0.001 至 ×1000 的极端压力测试。结果按目标等权，并使用 500 次食品记录级配对 bootstrap。该分析只针对冻结的单种子模型和域内验证集。

6.2 局部扰动与删除



Sensitivity dose response

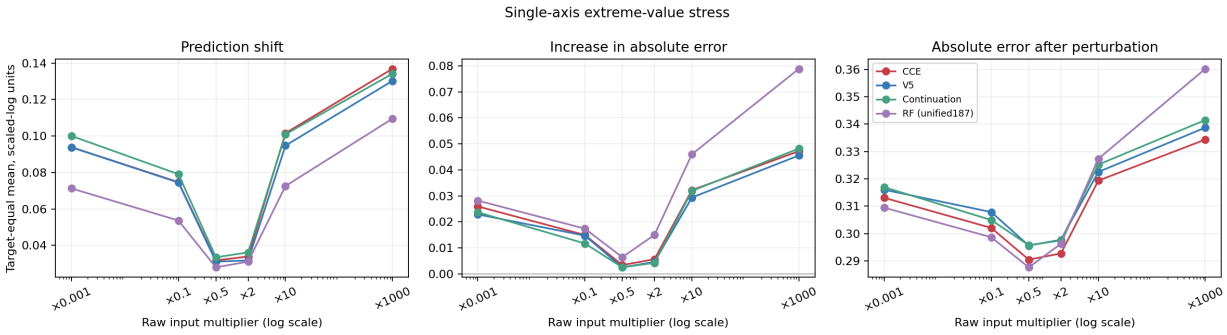
模型	条件	Prediction shift	Error delta	Perturbed error
CCE	-10%	0.00523	0.00003	0.28718
CCE	+10%	0.00467	0.00029	0.28744
RF	-10%	0.00793	0.00056	0.28186

模型	条件	Prediction shift	Error delta	Perturbed error
RF	+10%	0.00643	0.00195	0.28325
CCE	移除	0.05898	0.00789	**0.29169**
RF	移除	0.07182	0.03401	0.31291

在 ±10% 日常量级扰动下，CCE 和 RF 的平均误差增量都很小，CCE 的退化更少，但 RF 在干净验证集上的原始 scaled-log MAE 略低（0.2900 对 0.2947），因此小扰动后 RF 的绝对误差仍较低。输入移除时，CCE 的误差增量约为 RF 的 23%，并且扰动后绝对误差也更低，显示对缺失输入有更明显的稳健性。

CCE 与 V5/continuation 的差异较小。+10% 和输入移除时，CCE 的 error delta 甚至略高于 V5，但它的干净误差更低，所以扰动后绝对误差仍更低。这说明现有结果支持最终 CCE checkpoint 的整体表现，却没有证明 CCE objective 本身带来了额外的抗扰动能力。

6.3 极端压力测试



Sensitivity stress test

在 ×1000 条件下，CCE 的 prediction shift 为 0.1369，高于 RF 的 0.1095；但 CCE 的 error delta 为 0.0472，低于 RF 的 0.0789，最终扰动后误差也更低（0.3343 对 0.3602）。这再次说明“预测移动更大”不等于“预测更脆弱”。在 ×0.001 条件下则呈混合结果：CCE 退化稍小，但 RF 的扰动后绝对误差仍较低。

这些极端倍数用于发现数值失稳和不合理响应。所有方法均未产生非有限输出，但这不代表极端输入在科学上合理或安全。

6.4 有结构的跨轴依赖

全量分析中，蛋白质和水的 +10% 扰动在数千食品、128 个目标上分别产生约 0.0105 和 0.0101 的目标等权 prediction shift，说明模型广泛利用这些轴。联合增加宏量营养输入 10% 时，20 个氨基酸目标的 CCE 预测明显变化；但在该特定案例中 RF 的误差增量和扰动后误差都低于 CCE。因此这项结果说明模型学到了宏量营养与氨基酸之间的预测关联，却不是 CCE 独有能力，也不是营养因果证据。

7. 综合判断

主张	支持证据	反证或限制	当前判断
模型能跨数据库零样本迁移	台湾 TFDA 上 SLMAE 显著优于三种 baseline；名称新颖面板一致	只覆盖 80/187 轴；单位映射与最低支持筛选	**支持较强**
预训练提高新数据库的样本效率	8/32/128 shot 均明显优于相同架构 scratch	仅 3 seed；scratch 未单独调参	**支持较强**
少量台湾标签总能改善模型	128-shot 明显改善	8-shot 比零样本更差，32-shot 收益弱	**不支持普遍成立**

主张	支持证据	反证或限制	当前判断
FOOD embedding 形成有意义表征	类别局部纯度高于随机标签，CCE 比 V5 略好	原始数值+mask 更强；来源和缺失模式混杂	**部分支持，描述性**
模型在低观测下有优势	10-40 个观测及 routine panel 优于 RF/KNN	5 个观测时 KNN 更好；仅 12 目标	**条件性支持**
CCE 本身带来主要收益	最终 checkpoint 在多项任务最好	continuation 经常接近；稳健性未显示一致 CCE 优势	**证据不足**
Transformer 比 RF 更抗扰动	输入移除和部分极端条件下 CCE 退化更小	小扰动后 RF 绝对误差仍可能更低；结构化案例 RF 更好	**取决于扰动和指标**

最稳妥的最终表述是：

> 在不使用食品名称或来源的条件下，V5+CCE
> 在独立台湾数据库上展示了明确的零样本补全优势；以同架构随机初始化为对照，预训练在 8-128 个外部适配食品下显著提高样本效率。模型在中等数量可见成分时还能保持较好的补全能力。表征可视化和敏感性分析说明模型确实利用了跨轴组成结构，同时也揭示了来源缺失模式、极低样本微调和极端输入带来的限制。

8. 局限与下一步

1. 台湾面板只覆盖 80 个可兼容且支持充分的轴，不能直接外推到全部 187 个监督轴。
2. 名称精确不匹配不等同于食品语义完全新颖；不同数据库中的近似食品仍可能存在。
3. 少样本实验使用一个固定 400 食品测试集和三个抽样 seed，尚未覆盖测试划分不确定性。
4. 预训练和 scratch 使用相同学习率与训练轮数以保证协议一致，但这不等于各自最优超参数。
5. UMAP、少观测和 sensitivity 都是在原验证集上的探索性分析，不应用来声称未见来源泛化。
6. 敏感性实验固定目标真值而改变输入，可能破坏真实食品的质量守恒和化学一致性；它衡量模型响应，不直接等同于真实干预。
7. 当前结果来自一个主模型 checkpoint。下一步应在外部 few-shot 上增加模型 seed 和测试划分重复，并加入冻结 encoder + 小型适配头、全参数微调和正则化微调的预先登记比较。

9. 复现与附件

- `tables/taiwan_zero_shot_metrics.csv`：台湾零样本三项指标与区间。
- `tables/taiwan_zero_shot_paired_bootstrap.csv`：零样本 paired bootstrap 差异。
- `tables/taiwan_fewshot_summary.csv`：少样本 3-seed 汇总。
- `tables/taiwan_fewshot_runs.csv`：18 个独立训练运行。
- `fewshot_verification.json`：157 项完整性检查，全部通过。
- `tables/sparse_observation_summary.csv`：少观测补全曲线。
- `tables/umap_category_metrics.csv` 与 `tables/umap_robustness.csv`：表征定量结果。
- `tables/sensitivity_key_results.csv`、`tables/sensitivity_verdicts.csv`：全验证集敏感性关键结果。
- `manifest.json`：本报告文件与上游关键输入的 SHA256。